

SISTEMA DE ALERTA TEMPRANA

Predicción de Accidentalidad Urbana en Medellín

Informe técnico del taller de Aprendizaje Automático

Luisa Álvarez, Wendy Benítez, Santiago Gómez y Santiago Neusa
Mayo de 2026

1. Resumen

Este informe presenta el desarrollo completo de un sistema de predicción de accidentalidad urbana para la ciudad de Medellín, Colombia, construido sobre registros históricos de accidentes de tránsito (2017–2019) cruzados con datos meteorológicos horarios por barrio. El objetivo es predecir si ocurrirá al menos un accidente en una combinación específica de barrio y hora, habilitando el despliegue preventivo de recursos de seguridad vial.

El problema se formula como clasificación binaria con desbalance extremo: la clase positiva representa el 1.51% de las observaciones. Se evaluaron modelos baselines, regresión logística, Random Forest y HistGradientBoosting, con dos estrategias de balanceo (class_weight y undersampling). El modelo ganador fue el HistGradientBoostingClassifier con class_weight='balanced', validado mediante TimeSeriesSplit para respetar la causalidad temporal.

Hallazgos principales



- **Discriminación sólida:** ROC-AUC = 0.8184, significativamente superior al azar (0.50).
- **Valor sobre la prevalencia:** PR-AUC = 0.0848 representa 5.1× la tasa base de accidentalidad (1.47%), confirmando señal predictiva real.
- **Umbral orientado a recall:** se seleccionó max-F2 ($\beta=2$, umbral=0.7842) para priorizar la cobertura de accidentes reales sobre la reducción de falsas alarmas, acorde con la asimetría de costos en seguridad vial.
- **Concentración espaciotemporal:** los accidentes se concentran en horas pico (17h–19h) y en barrios de alta densidad vial como La Candelaria, Campoamor y Perpetuo Socorro.
- **Viabilidad operativa:** el modelo permite guiar operativos preventivos 5× más eficientes que una distribución aleatoria de recursos.

Recomendación

Se recomienda desplegar el modelo como sistema de alerta temprana de nivel 1 dentro de la Secretaría de Movilidad de Medellín, generando diariamente un ranking de los Top-20 barrios × franjas horarias de mayor riesgo predicho. El sistema debe complementarse con retroalimentación operativa semanal, reentrenamiento periódico y enriquecimiento gradual con variables externas (meteorología en tiempo real, eventos masivos, obras viales).

2. Descripción del Problema y los Datos

2.1 Definición del problema

La accidentalidad vial es un problema de salud pública de primer orden en Medellín. El objetivo de este trabajo es construir un clasificador binario que prediga, para cada combinación (barrio × ventana temporal de 1 hora), si ocurrirá al menos un accidente de tránsito. Esta formulación convierte el problema en una tarea de predicción prospectiva que puede alimentar sistemas de alerta y despliegue preventivo de recursos.

2.2 Fuentes de datos

Tabla	Registros	Período	Variables	Descripción
accidents	120,587	2017–2019	8	Accidentes geocodificados por barrio y hora (tabla agregada)
weather	7,991,780	2017–2019	15	Condiciones meteorológicas horarias por barrio (temperatura, lluvia, viento, etc.)
raw	125,122	2017–2019	22	Registros individuales de accidentes con detalle de clase, gravedad, dirección y comuna

2.3 Construcción del dataset

El dataset se construye haciendo un LEFT JOIN de la tabla *weather* (unidad mínima barrio × hora) con los accidentes agregados. Cada fila del dataset resultante representa un barrio × hora y tiene un target binario: 1 si ocurrió al menos un accidente, 0 en caso contrario. El dataset final contiene **7,991,780 filas**, 319 barrios únicos y cubre tres años completos (2017-01-01 a 2019-12-31).

Característica	Valor
Total de observaciones	7,991,780
Clase positiva (target=1)	120,475 (1.51%)
Clase negativa (target=0)	7,871,305 (98.49%)
Barrios únicos	319
Rango temporal	2017-01-01 → 2019-12-31
Valores nulos totales (weather)	3,276,350 (principalmente windBearing 12.9%, precipIntensity 6.9%)

3. Análisis Exploratorio de Datos (EDA)

3.1 Distribución del target

El desbalance de clases es extremo: menos del 2% de las combinaciones barrio-hora registran al menos un accidente. Este hecho es fundamental para el diseño del pipeline de modelado, ya que métricas como la accuracy resultan engañosas (un clasificador trivial que predice siempre "sin accidente" alcanza 98.5% de accuracy con recall = 0).




Figura 1. Distribución de la variable objetivo. El desbalance extremo (98.5% vs 1.5%) justifica el uso de PR-AUC como métrica primaria.

3.2 Patrones temporales

El análisis temporal revela patrones claros de accidentalidad que tienen implicaciones directas para el modelo predictivo y el diseño de operativos preventivos.




Figura 2. Distribución horaria de accidentes (2017-2019). El pico principal se presenta entre las 17h y 19h, correspondiendo con la hora de mayor flujo vehicular.




Figura 3. Accidentes por día de la semana. Los viernes registran la mayor accidentalidad (~20,200 accidentes), mientras el domingo presenta el menor número (~11,500).

Hallazgos clave del análisis temporal: el 70% de los accidentes ocurre en días laborables, con picos claros en las horas de entrada (7h–9h) y salida (17h–19h) del trabajo. El mayor pico absoluto se presenta los viernes en la franja 17h–18h, sugiriendo un efecto combinado de volumen vehicular alto y fatiga de fin de semana.

3.3 Distribución espacial




Figura 4. Top 15 barrios con mayor accidentalidad acumulada. La Candelaria, Campoamor y Perpetuo Socorro concentran la mayor siniestralidad, coherente con su alta densidad de corredores viales comerciales.

A nivel de comunas, La Candelaria (centro) concentra la mayor accidentalidad con más de 25,000 accidentes en el período, seguida de Laureles-Estadio y Castilla. Esta concentración está correlacionada con la densidad de actividad comercial, flujo vehicular y presencia de intersecciones complejas.

3.4 Relación clima y accidentalidad




Figura 5. Matriz de correlación entre variables climáticas y target. La temperatura muestra correlación positiva (0.19) y la humedad negativa (-0.12) con la ocurrencia de accidentes.

Las correlaciones lineales con el target son moderadas pero consistentes: mayor temperatura y viento se asocian con mayor probabilidad de accidente, mientras que mayor humedad (asociada a lluvia) muestra correlación levemente negativa. Sin embargo, estas relaciones son más complejas e interactivas, lo que justifica el uso de modelos no lineales como el HistGradientBoosting.

4. Tratamiento de Calidad de Datos

4.1 Reporte de valores nulos

Tabla	Columna	Valores faltantes	% del total	Decisión
raw_accidents	MES_NOMBRE	82,740	66.1%	No usada como feature (columna redundante)
weather	windBearing	1,032,513	12.9%	Imputación por mediana en pipeline de preprocesamiento
weather	summary/icon	548,641	6.9%	Frequency encoding; nulos se tratan como categoría propia
weather	precipIntensity	547,401	6.9%	Imputación por mediana (distribución sesgada a la derecha)
weather	precipProbability	547,401	6.9%	Imputación por mediana
weather	windSpeed	32,793	0.4%	Imputación por mediana
weather	cloudCover/uvIndex/visibility	~16,500	0.05%–0.1%	Imputación por mediana
raw_accidents	RADICADO	5	<0.01%	Registros descartados (clave nula)
raw_accidents	DISEÑO	429	0.34%	Columna no usada como feature

4.2 Duplicados

La revisión de duplicados sobre las llaves primarias encontró resultados satisfactorios. En la tabla *accidents* no hay duplicados por (TW, BARRIO). En la tabla *weather* tampoco hay duplicados por (TW, BARRIO). En *raw_accidents* se identificaron 21 registros con RADICADO duplicado, que corresponden a accidentes múltiples con el mismo número de radicación (posiblemente multi-vehículo). Dado que el target binario solo requiere saber si hubo al menos un accidente, este aspecto no afecta la validez del dataset.

4.3 Validación de rangos climáticos

Variable	Rango esperado	Mín. real	Máx. real	Fuera de rango
temperature	-10 a 50 °C	4.51 °C	35.99 °C	0
apparentTemperature	-15 a 55 °C	4.51 °C	38.06 °C	0
humidity	0 a 1	0.17	1.00	0
precipProbability	0 a 1	0.00	1.00	0
cloudCover	0 a 1	0.00	1.00	0
uvIndex	0 a 20	0.00	14.00	0
visibility	0 a 20 km	0.099	16.093	0

Ninguna variable climática presenta valores fuera de los rangos físicamente esperados para la región de Medellín. Los outliers detectados por IQR en *precipIntensity* (10.7% de filas) y *windSpeed* (5.3%) corresponden

a eventos meteorológicos extremos válidos y se conservaron en el dataset, ya que su eliminación podría sesgar el modelo hacia condiciones climáticas normales.

4.4 Consistencia de barrios entre tablas

La comparación entre los barrios presentes en *accidents* y *weather* reveló que 3 barrios aparecen en *accidents* pero no en *weather*: ELASTILLERO, SUBURBANOAGUASFRIAS y YARUMALITO. Estos 3 barrios representan una fracción mínima del total de registros y sus observaciones se excluyeron del dataset final, ya que no es posible construir features climáticas para ellos.

4.5 Formato y alineación temporal

Todas las tablas tienen la columna TW (Time Window) correctamente truncada a la hora exacta, sin valores con minutos o segundos residuales. La cobertura temporal es continua para los tres años analizados (2017-01-01 a 2019-12-31), sin huecos de fechas completas.

5. Ingeniería de Características

El vector de features final contiene **29 variables** distribuidas en cinco grupos. El pipeline de preprocesamiento aplica imputación por mediana y estandarización (StandardScaler) sobre todas las variables numéricas. Los encodings se ajustan exclusivamente con datos de entrenamiento para evitar fuga de información desde el conjunto de test.




Figura 6. (Izquierda) Representación cíclica de la hora del día mediante sin/cos, que preserva la continuidad entre las 23h y las 0h. (Derecha) Composición del vector de features por grupo.

5.1 Features temporales básicas (6 variables)

Feature	Descripción	Justificación
hour	Hora del día (0–23)	Captura los picos horarios de tráfico
weekday_num	Día de la semana (0=lunes, 6=domingo)	Patrones laborables vs. fines de semana
is_weekend	Indicador binario (sábado o domingo)	Diferencia comportamiento de movilidad
is_holiday	Indicador de día festivo	Festivos cambian patrones de circulación
time_period	Franja del día (early_morning, morning...)	Segmentación operativa del día
month_sin/cos	Mes del año codificado cíclicamente	Captura estacionalidad mensual sin discontinuidades

5.2 Features cíclicas sin/cos (8 variables)

Las variables hour, weekday y dayOfYear se codifican como pares (sin, cos) usando la transformación $f(x) = (\sin(2\pi x/T), \cos(2\pi x/T))$. Esta codificación es esencial porque los modelos de árbol tratan las variables numéricas como ordinales: sin ella, la hora 23 aparecería como "lejana" de la hora 0, cuando operativamente son adyacentes. Las 8 features resultantes son: *hour_sin*, *hour_cos*, *weekday_sin*, *weekday_cos*, *dayOfYear_sin*, *dayOfYear_cos*, *month_sin*, *month_cos*.

5.3 Features históricas de ventana deslizante (4 variables)

Feature	Ventana	Descripción
hist_acc_neighborhood_total	Todo el historial	Total acumulado de accidentes en el barrio hasta el instante t-1
hist_acc_neighborhood_30d	Últimos 30 días	Accidentes recientes en el barrio (captura tendencias de corto plazo)
hist_acc_hour_neighborhood	Todo el historial	Accidentes históricos en la combinación específica barrio × hora

Feature	Ventana	Descripción
hist_rate_neighborhood	Todo el historial	Tasa de accidentalidad normalizada por total de horas observadas

Estas features son las de mayor poder predictivo, ya que capturan el riesgo estructural de cada barrio. Se calculan con información estrictamente anterior al instante de predicción (t-1) para evitar fuga temporal. En el período inicial (2017) los valores son cercanos a cero por ausencia de historial acumulado.

5.4 Features climáticas (11 variables)

Se incluyen todas las variables meteorológicas disponibles: temperature, apparentTemperature, dewPoint, humidity, precipIntensity, precipProbability, windSpeed, windBearing, cloudCover, uvIndex y visibility. Aunque sus correlaciones individuales con el target son moderadas, aportan señal predictiva especialmente en interacción con variables temporales y espaciales.

5.5 Encoding de variables categóricas (4 variables)

Variable	Tipo de encoding	Justificación
BARRIO	Target Encoding (smoothing=10)	Alta cardinalidad (319 barrios). El smoothing evita sobreajuste en barrios con pocos registros
summary	Frequency Encoding	Descripción textual del clima (ej: "Mostly Cloudy"). Se reemplaza por su frecuencia en train
icon	Frequency Encoding	Icono de condición climática. Codificado igual que summary
time_period	Frequency Encoding	Categoría de franja horaria (4 valores posibles)

El Target Encoder se ajusta únicamente con datos de entrenamiento y aplica suavizado (smoothing=10) para que la estimación de barrios con pocos registros se aproxime a la media global, mitigando el sobreajuste. El Frequency Encoder también se ajusta solo en train y transforma los valores de test usando las frecuencias aprendidas.

5.6 División temporal train/test

El dataset se ordena cronológicamente por TW y se divide en 80% train (2017-01-01 → 2019-05-22) y 20% test (2019-05-22 → 2019-12-31), **sin shuffling**. Esta partición garantiza que el modelo nunca ve información futura durante el entrenamiento, respetando la causalidad del problema temporal.

6. Modelos Comparados, Hiperparámetros y Métricas

6.1 Justificación de métricas

Dado el desbalance extremo (1.5% de positivos), la accuracy es una métrica inadecuada: los baselines triviales alcanzan 98.3% de accuracy con recall = 0. Las métricas seleccionadas son:

Métrica	Rol	Por qué se usa
PR-AUC	Métrica PRIMARIA	Resume el desempeño en todo el rango de umbrales; no se infla con los TN; referencia directa es la prevalencia
ROC-AUC	Métrica complementaria	Capacidad de ranking general; con desbalance extremo puede ser optimista
Precision	Operativa	Fracción de alertas que corresponden a accidentes reales (costo de falsos positivos)
Recall	Operativa	Fracción de accidentes detectados (costo de falsos negativos; el más crítico en seguridad vial)
F1 / F2	Selección de umbral	Media armónica P-R; F2 ($\beta=2$) pondera el recall el doble que la precision

6.2 Comparación de modelos




Figura 7. Comparación de PR-AUC y ROC-AUC para todos los modelos evaluados. HistGB tuneado obtiene el mejor PR-AUC (0.0848), representando 5.1× la prevalencia base.

Modelo	Estrategia	Accurac y	Precisio n	Recall	F1	ROC-AUC	PR-AUC
Dummy (most_freq)	—	0.983	0.000	0.000	0.000	0.500	0.017
Dummy (stratified)	—	0.969	0.018	0.016	0.016	0.500	0.017
LogReg	class_weight	0.779	0.048	0.659	0.090	0.791	0.078
LogReg	tuned	0.778	0.048	0.661	0.090	0.791	0.078
RandomForest	class_weight	0.788	0.049	0.644	0.092	0.808	0.071
RandomForest	tuned	0.650	0.038	0.813	0.072	0.815	0.083

Modelo	Estrategia	Accurac y	Precisio n	Recall	F1	ROC-AUC	PR-AUC
HistGB	class_weight	0.672	0.039	0.800	0.075	0.818	0.086
HistGB	tuned ✓	0.651	0.038	0.820	0.072	0.818	0.085

6.3 Hiperparámetros del ajuste fino (RandomizedSearchCV + TimeSeriesSplit)

El tuning se realizó con RandomizedSearchCV, TimeSeriesSplit(n_splits=5) y scoring=average_precision, sobre una submuestra temporal de ~1M filas (cada 5ª fila del train completo) para mantener cobertura temporal sin exceder el presupuesto de cómputo.

Modelo	Hiperparámetro	Valor óptimo	Espacio explorado	Nota
LogReg	C (regularización)	0.0020	loguniform(1e-3, 1e2)	Regularización muy fuerte → señal principalmente lineal saturada
LogReg	penalty	l2	["l2"]	—
RF	n_estimators	188	randint(100, 300)	—
RF	max_depth	8	randint(8, 25)	Default 15 sobreajustaba; tuning encontró 8
RF	min_samples_split	13	randint(2, 20)	—
RF	max_features	log2	["sqrt", "log2"]	—
HistGB	max_iter	152	randint(100, 400)	—
HistGB	max_depth	5	randint(4, 12)	Árboles superficiales → problema de alto ruido
HistGB	learning_rate	0.0371	loguniform(0.01, 0.3)	Tasa conservadora, estable
HistGB	min_samples_leaf	149	randint(20, 200)	Hojas grandes reducen sobreajuste temporal
HistGB	l2_regularization	0.0179	loguniform(1e-4, 1.0)	—

7. Estrategia de Balanceo y Justificación

7.1 Estrategias evaluadas

Se compararon dos paradigmas de balanceo sobre las tres familias de modelos, usando PR-AUC como criterio principal:

Estrategia	Descripción	Modifica datos	Tamaño train
<code>class_weight="balanced"</code>	Reponderación de la función de pérdida inversamente proporcional a la frecuencia de clase	No	6,393,424 filas
Undersampling 1:5	Submuestreo aleatorio de negativos hasta 5 negativos por cada positivo	Sí	563,562 filas (~9%)




Figura 8. Comparación de PR-AUC por modelo y estrategia de balanceo. Ambas estrategias producen PR-AUC casi idéntico; `class_weight` se prefiere por conservar el dataset completo.

7.2 Decisión: `class_weight="balanced"`

La estrategia seleccionada fue `class_weight="balanced"`, por las siguientes razones:

- **PR-AUC equivalente:** ambas estrategias producen PR-AUC casi idéntico (~0.085) en todos los modelos. Lo que cambia es el umbral implícito, no la capacidad de ranking.
- **Conserva información temporal:** el dataset completo (6.4M filas) contiene tres años de historia sobre cuándo NO ocurrieron accidentes, que también es señal. El undersampling descarta el 91% de esa información.
- **Mayor estabilidad:** el undersampling introduce varianza adicional por la aleatoriedad de la muestra, que se acumula en los 5 folds de validación cruzada temporal.
- **Consistencia entre folds:** con `class_weight`, cada fold de `TimeSeriesSplit` trabaja sobre los datos reales en su proporción natural, evitando distribuciones artificiales durante la validación.
- **Costo computacional:** evitar la reducción de datos permite entrenar sobre el conjunto completo sin pérdida de cobertura temporal.

8. Modelo Final, Métricas y Umbral de Decisión

8.1 Descripción del modelo final

Componente	Decisión	Justificación
Algoritmo	HistGradientBoostingClassifier	Mejor PR-AUC (0.0848) y ROC-AUC (0.818) en test; costo computacional inferior a RandomForest
Balanceo	class_weight='balanced'	Conserva el dataset completo; PR-AUC idéntico al undersampling pero más estable
Datos de entrenamiento	X_train completo (6.4M filas)	El umbral ya fue fijado sobre val_inner; más datos = mejor generalización
Umbral de decisión	max-F2 ($\beta=2$) = 0.7842	Penaliza falsos negativos: en seguridad vial, no detectar un accidente cuesta más que una falsa alarma

8.2 Estrategia de validación (dos capas)

Se implementó una estrategia de validación en dos capas para garantizar una evaluación honesta y libre de fuga temporal:

- **Capa 1 — Partición temporal interna:** X_train se divide en train_inner (80%) y val_inner (20%) sin shuffle, respetando el orden cronológico. El umbral de decisión se seleccionó exclusivamente sobre val_inner.
- **Capa 2 — Validación cruzada temporal:** TimeSeriesSplit(n_splits=5) sobre submuestra de train_inner para medir la estabilidad del modelo. Cada fold respeta la causalidad: el validation es siempre cronológicamente posterior al train.
- **Conjunto de test (X_test) completamente aislado:** no se usó en ningún momento del proceso de ajuste ni de selección de umbral. Sirve exclusivamente para la evaluación final.




Figura 9. Estabilidad temporal del HistGradientBoosting. PR-AUC media = 0.0747 ± 0.0056 y ROC-AUC media = 0.8218 ± 0.0154 en 5 folds de TimeSeriesSplit, confirmando generalización consistente.

8.3 Selección del umbral de decisión

Se evaluaron dos criterios de umbral sobre val_inner barriendo la curva Precision–Recall:

Criterio	Fórmula	Umbral	Precision	Recall	F-score	Elección
max-F1	$\beta=1$, media armónica P-R	0.8579	10.4%	23.9%	F1=0.1449	—
max-F2	$\beta=2$, recall vale el doble	0.7842	8.0%	36.9%	F2=0.2143	✓ ELEGIDO

Se eligió el umbral **max-F2 ($\beta=2$)** porque en seguridad vial la asimetría de costos es clara: un accidente no detectado (falso negativo) puede costar vidas humanas, mientras que una alerta innecesaria (falso positivo) solo implica un operativo preventivo sin justificación. El parámetro $\beta=2$ formaliza que el recall vale el doble que la precisión en la función objetivo.





Figura 10. Curva Precision-Recall sobre val_inner con los dos umbrales evaluados. El punto max-F2 (naranja) se selecciona como umbral final por maximizar la cobertura de accidentes reales.

8.4 Métricas finales en test



La evaluación final sobre X_{test} , que no participó en ninguna etapa del desarrollo, confirma que el modelo mantiene el desempeño observado durante la validación. El PR-AUC de 0.0848 representa **5.1× la prevalencia base** (0.017), confirmando señal predictiva real más allá de una estrategia aleatoria o la simple repetición del patrón histórico.




Figura 11. Matriz de confusión del modelo final (umbral max-F2 = 0.7842 sobre 1,598,356 observaciones de test). De 26,548 accidentes reales, el modelo detecta 9,325 (recall=35.1%).

Cuadrante	Valor	% del total	Interpretación operativa
TN (verdaderos negativos)	1,483,585	92.82%	Horas-barrio sin accidente, correctamente descartadas
FP (falsas alarmas)	88,223	5.52%	Alertas emitidas donde no hubo accidente → operativo innecesario
FN (falsos negativos)	17,223	1.08%	Accidentes no detectados → el costo más alto en seguridad vial
TP (verdaderos positivos)	9,325	0.58%	Accidentes anticipados → alertas útiles para operativos preventivos

8.5 Interpretación operativa del umbral

- **Recall = 35.1%:** el modelo detecta 1 de cada 3 accidentes reales antes de que ocurran, suficiente para guiar un despliegue preventivo focalizado.
- **Precision = 9.6%:** de cada 100 alertas, ~10 corresponden a un accidente real. Este nivel es aceptable en seguridad vial, donde el costo de un FN supera con creces el de un FP.
- **Eficiencia relativa:** concentrar los operativos en las celdas marcadas como alto riesgo es ~5× más eficiente que una distribución aleatoria sobre el mismo número de celdas.
- **Flexibilidad:** la curva PR permite ajustar el umbral en producción sin reentrenar: subir el umbral reduce alertas y aumenta precisión; bajarlo aumenta la cobertura a costa de más falsas alarmas.

9. Caso de Uso Propuesto y Limitaciones

9.1 Sistema de Alerta Temprana — Secretaría de Movilidad de Medellín

El modelo se propone como herramienta de apoyo a la decisión para la Secretaría de Movilidad de Medellín, desplegado como sistema de alerta temprana de accidentalidad que genera diariamente un ranking de barrios × franjas horarias de mayor riesgo predicho.

9.2 Flujo operativo diario automatizado

Paso	Horario	Acción
1	00:00–01:00	Ingesta nocturna: el pipeline de features actualiza las variables históricas (hist_last_7d, hist_last_4w, etc.) con los datos del día anterior.
2	01:00–01:30	Scoring: el modelo genera probabilidades para cada combinación barrio × hora de las próximas 24 horas.
3	06:00	Alerta matutina: el sistema envía al Centro de Control de Tránsito un reporte con el Top-20 de barrios × franjas horarias de mayor riesgo predicho.
4	Según alerta	Despacho preventivo: el Centro asigna unidades de Policía de Tránsito y señalización temporal a las franjas de mayor riesgo.
5	23:00	Retroalimentación: los accidentes reportados se comparan con las alertas emitidas para calcular métricas operativas semanales y detectar deriva del modelo.

9.3 Variables externas que mejorarían el modelo

Variable	Fuente sugerida	Justificación
Eventos masivos (conciertos, partidos, marchas)	Secretaría de Cultura · API Ticketmaster	Concentran flujo vehicular en horarios y zonas específicas
Obras viales activas	SIMCO · Secretaría de Infraestructura	Desvíos y reducción de carriles incrementan riesgo
Velocidad del tráfico en tiempo real	Google Maps Platform · Waze for Cities	Variable directamente relacionada con severidad y frecuencia de accidentes
Estado del pavimento	Inventario Vial Municipal	Vías con huecos o señalización deficiente presentan mayor siniestralidad
Infracciones por zona	Base de comparendos (Tránsito Medellín)	Proxy del comportamiento de riesgo habitual de los conductores
Condiciones meteorológicas en tiempo real	IDEAM · OpenWeatherMap API	La lluvia intensa incrementa accidentalidad especialmente en motocicletas

9.4 Limitaciones del modelo

#	Limitación	Impacto potencial
1	Deriva temporal: entrenado con datos 2017–2019; cualquier despliegue futuro enfrenta patrones de movilidad diferentes.	Degradación gradual del PR-AUC y Recall en producción. Requiere reentrenamiento periódico.

#	Limitación	Impacto potencial
2	Componente estocástica: factores humanos puntuales (distracción, estado del conductor) son inherentemente impredecibles.	Techo teórico del PR-AUC limitado; no es posible capturar el ruido aleatorio del sistema de tránsito.
3	Precisión baja (9.6%): por cada 100 alertas, ~10 corresponden a accidentes reales.	Riesgo de fatiga de alerta si los operadores reciben demasiadas falsas alarmas sin retroalimentación.
4	Sesgo geográfico: barrios con pocos registros históricos tienen features de ventana deslizante cercanas a cero.	Subestimación del riesgo en barrios periféricos con bajo historial de reportes oficiales.
5	Interpretabilidad limitada: HistGradientBoosting es una caja negra.	Dificultad para justificar decisiones ante la ciudadanía y organismos de control. Se recomienda SHAP.
6	Granularidad espacial: el nivel de barrio puede esconder variabilidad interna entre cuadras.	Una resolución más fina (intersección, segmento vial) mejoraría las métricas.

10. Conclusiones y Trabajo Futuro

10.1 Conclusiones

Sobre el modelado

- **La accuracy es una métrica engañosa** con desbalance extremo: los baselines triviales alcanzan 98.3% de accuracy con recall = 0. Esto justifica el uso de PR-AUC, precision y recall sobre la clase positiva como criterios de selección.
- **HistGradientBoosting es el modelo ganador** con PR-AUC = 0.0848 (5.1× la prevalencia base), ROC-AUC = 0.8184 y el mayor recall al umbral por defecto (0.82). Su costo computacional es muy inferior al de RandomForest, relevante para reentrenamiento periódico.
- **Las dos estrategias de balanceo rankean igual:** class_weight y undersampling 1:5 producen PR-AUC casi idéntico (~0.085). La elección de class_weight se justifica por conservar la información completa del entrenamiento y mayor estabilidad entre folds.
- **El tuning aporta diferenciadamente:** HistGB se mantiene en el tope con o sin tuning (PR-AUC ≈ 0.085), RandomForest mejora +16.5% con tuning (max_depth reducido de 15 a 8), y LogReg está saturado (el problema tiene estructura no lineal).
- **El umbral max-F2 ($\beta=2$)** es la elección correcta para este dominio: formaliza que detectar accidentes (recall) es más valioso que evitar falsas alarmas, coherente con la asimetría de costos en seguridad vial.

Sobre la viabilidad operativa

- El modelo presenta **discriminación sólida:** ROC-AUC = 0.8184 es suficiente para ordenar correctamente el riesgo relativo entre zonas horarias.
- El PR-AUC de 0.0848 representa un **valor real sobre la prevalencia** (5.1×), confirmando que el modelo agrega información más allá de una estrategia aleatoria.
- Los **patrones espaciotemporales accionables** identificados (concentración en La Candelaria, viernes 17h–19h) pueden guiar operativos preventivos incluso antes de un despliegue completo.
- Las limitaciones (precisión baja, deriva temporal) son **gestionables mediante calibración continua** y retroalimentación operativa.

10.2 Trabajo futuro

Área	Acción propuesta	Impacto esperado
Variables externas	Integrar datos de clima en tiempo real (IDEAM), eventos masivos y obras viales	Mejora de PR-AUC estimada +20–30%
Resolución espacial	Desagregar de barrio a intersección o segmento vial ($\leq 500\text{m}$)	Mayor precisión geográfica; reduce variabilidad interna de barrios grandes
Interpretabilidad	Implementar explicaciones SHAP para cada predicción	Facilita adopción institucional y justificación de decisiones operativas
Monitoreo en producción	Calcular semanalmente PR-AUC y recall sobre datos recientes; alertas de deriva	Detecta degradación del modelo antes de que afecte la operación
Reentrenamiento automático	Pipeline de reentrenamiento mensual con datos actualizados	Mantiene relevancia del modelo ante cambios de patrones de movilidad
Severidad	Modelar gravedad del accidente (solo daños / heridos / muertos) como segunda capa	Permite priorizar recursos según severidad esperada, no solo probabilidad
Modelos secuenciales	Explorar LightGBM con features de lag explícitas o modelos de series de tiempo por barrio	Potencial mejora de PR-AUC aprovechando autocorrelación temporal

Área	Acción propuesta	Impacto esperado
Validación en tiempo real	Piloto con datos del año en curso (2025–2026)	Prueba real de la robustez del sistema ante patrones post-COVID y nuevas infraestructuras

10.3 Recomendación final

Se recomienda desplegar el modelo como **nivel 1 de alerta** dentro de un sistema multicapa de gestión de la accidentalidad urbana de Medellín. Este nivel genera el ranking diario de barrios × horas de alto riesgo basado en el modelo estadístico. Se debe complementar con análisis en tiempo real de condiciones atípicas (nivel 2) para reducir falsas alarmas y maximizar la utilidad operativa del sistema.

La inversión en un sistema de este tipo está justificada: el costo social de los accidentes de tránsito en Medellín supera ampliamente el costo de operativos preventivos adicionales, y un sistema que permite concentrar esos operativos 5× más eficientemente en las zonas y horarios de mayor riesgo predicho tiene un retorno social claramente positivo.

Resumen del Proyecto	Modelo Final
- Dataset: 7.99M filas · 319 barrios · 3 años (2017–2019) - Problema: clasificación binaria con desbalance extremo (1.51%) - Enfoque: validación temporal estricta (TimeSeriesSplit) - Features: 29 variables en 5 grupos (temporal, cíclicas, históricas, clima, encoding)	- Algoritmo: HistGradientBoostingClassifier - Balanceo: class_weight='balanced' - Umbral: max-F2 ($\beta=2$) = 0.7842 Recall = 35.1% - PR-AUC = 0.0848 (5.1× prevalencia) · ROC-AUC = 0.8184